



L'ÉCOLE DE L'INTELLIGENCE ARTIFICIELLE

SYNTHOSCORE
UNIFIED CREDIT EVALUATION ALGORITHM
MASTER IN ARTIFICIAL INTELLIGENCE &
MANAGEMENT
CYCLE GRANDE ECOLE

2022 - 2023

IAS-M2JV-DA1



SOMMAIRE

01

Introduction

02

Évaluation des
Risques de
Crédit

03

Intelligence
Artificielle et
Analyse Prédictive

04

Collecte et
Prétraitement
des Données

05

Modèle
SynthoScore

06

Conclusion



INTRODUCTION

- Introduction générale
- Objectifs de la présentation

INTRODUCTION

Période économique difficile due à l'inflation.

Recours accru aux emprunts bancaires pour maintenir la stabilité financière et réaliser des projets.

Les risques associés aux prêts bancaires pour les institutions financières

Objectifs de la présentation :

- Comprendre les enjeux de l'évaluation des risques de crédit dans le secteur bancaire.
- Présenter les méthodes traditionnelles de notation de crédit et leurs limites.
- Expliquer l'application de l'intelligence artificielle et de l'analyse prédictive pour améliorer l'évaluation des risques.
- Démontrer la collecte, le prétraitement des données et la création du modèle SynthoScore.
- Présenter les avantages anticipés du modèle pour les institutions financières.



ÉVALUATION DES RISQUES DE CRÉDIT

- Concept de risque de crédit
- Méthodes traditionnelles de notation de crédit et leurs limites
- Transition vers la nécessité d'une approche innovante

CONCEPT DE RISQUE DE CRÉDIT

- Définition du risque de crédit.
- Exemple de risque de crédit.
- Importance de la gestion du risque de crédit.



MÉTHODES TRADITIONNELLES DE NOTATION DE CRÉDIT ET LEURS LIMITES

- Présentation des méthodes traditionnelles de notation de crédit :
 1. Approche Expert
 2. Score Bayésien
 3. Régression Logistique.
- Avantages de ces méthodes, notamment leur utilisation de données subjectives et leur capacité à prendre en compte des informations non structurées.

LA NÉCESSITÉ D'UNE APPROCHE INNOVANTE

- Inconvénients des méthodes traditionnelles : Nous avons identifié les limitations majeures des méthodes traditionnelles de notation de crédit, telles que l'Approche Expert, le Score Bayésien et la Régression Logistique.
- Nécessité de repenser l'évaluation : Face à ces limitations, il est devenu essentiel de repenser la manière dont nous évaluons les risques de crédit.
- Motivation pour l'approche innovante : Nous avons constaté que l'environnement économique actuel, caractérisé par des incertitudes et des changements constants, exige une nouvelle approche.
- Annonce du modèle 'SynthoScore' : Pour répondre à ces besoins, nous allons présenter une approche innovante qui combine des données actualisées, des scores pondérés méticuleusement calculés et une régression logistique. Ce modèle, que nous appelons 'SynthoScore,' vise à améliorer la précision de l'évaluation des risques de crédit.



INTELLIGENCE ARTIFICIELLE ET ANALYSE PRÉdictive

- Introduction à l'IA et ses applications dans la finance
- Analyse prédictive et apprentissage automatique pour l'évaluation des risques de crédit
- Avantages de l'IA dans l'amélioration de l'évaluation des risques de crédit

INTRODUCTION À L'IA ET SES APPLICATIONS DANS LA FINANCE

Introduction :

- L'IA, une technologie révolutionnaire, transforme divers secteurs, dont la finance.
- Dans la finance, l'IA est utilisée pour automatiser des tâches complexes, analyser des données massives et améliorer la prise de décision.



ANALYSE PRÉdictive ET APPRENTISSAGE AUTOMATIQUE POUR L'ÉVALUATION DES RISQUES DE CRÉDIT

- Analyse prédictive :
 - Utilisation de données historiques et d'algorithmes pour prédire le risque de crédit.
 - Exemple : prédiction des défauts de paiement en se basant sur des antécédents de remboursement.
- Apprentissage automatique :
 - Formation de modèles pour détecter des tendances subtiles et modéliser les risques.
 - Exemple : utilisation de la régression logistique pour évaluer la probabilité de défaut.

AVANTAGES DE L'IA DANS L'AMÉLIORATION DE L'ÉVALUATION DES RISQUES DE CRÉDIT

- Précision accrue :
 - L'IA peut traiter d'énormes volumes de données avec une précision inégalée.
 - Réduction des erreurs humaines dans l'évaluation des risques.
- Détection de modèles complexes :
 - L'IA peut identifier des corrélations et des schémas non linéaires difficiles à repérer manuellement.
- Personnalisation des décisions :
 - Les modèles d'IA peuvent prendre en compte des facteurs uniques pour chaque emprunteur.



COLLECTE ET PRÉTRAITEMENT DES DONNÉES

- Types de données pertinentes et leur importance
- Défis liés à la collecte et à la qualité des données

COLLECTE ET PRÉTRAITEMENT DES DONNÉES

TYPES DE DONNÉES PERTINENTES ET LEUR IMPORTANCE

Liste des types de données :

Informations sur le Client :

- Customer_ID (Identifiant Client)
- Status_Checking_Acc : Historique de crédit du client.
- Savings_Acc : État du compte épargne du client.
- Credit_Amount : Montant du crédit demandé ou accordé.
- Inst_Rt_Income : Taux d'échéance en pourcentage du revenu.
- Years_At_Present_Employment : Durée de l'emploi actuel.

- Marital_Status_Gender : Situation matrimoniale et genre.
- Other_Debtors_Guarantors : Autres personnes impliquées dans la transaction.
- Current_Address_Yrs : Durée de résidence à l'adresse actuelle.
- Property : Détails sur la propriété du client.
- Age : L'âge du client.
- Other_Inst_Plans : Autres plans d'échéance du client.

COLLECTE ET PRÉTRAITEMENT DES DONNÉES

TYPES DE DONNÉES PERTINENTES ET LEUR IMPORTANCE

Informations sur le Prêt :

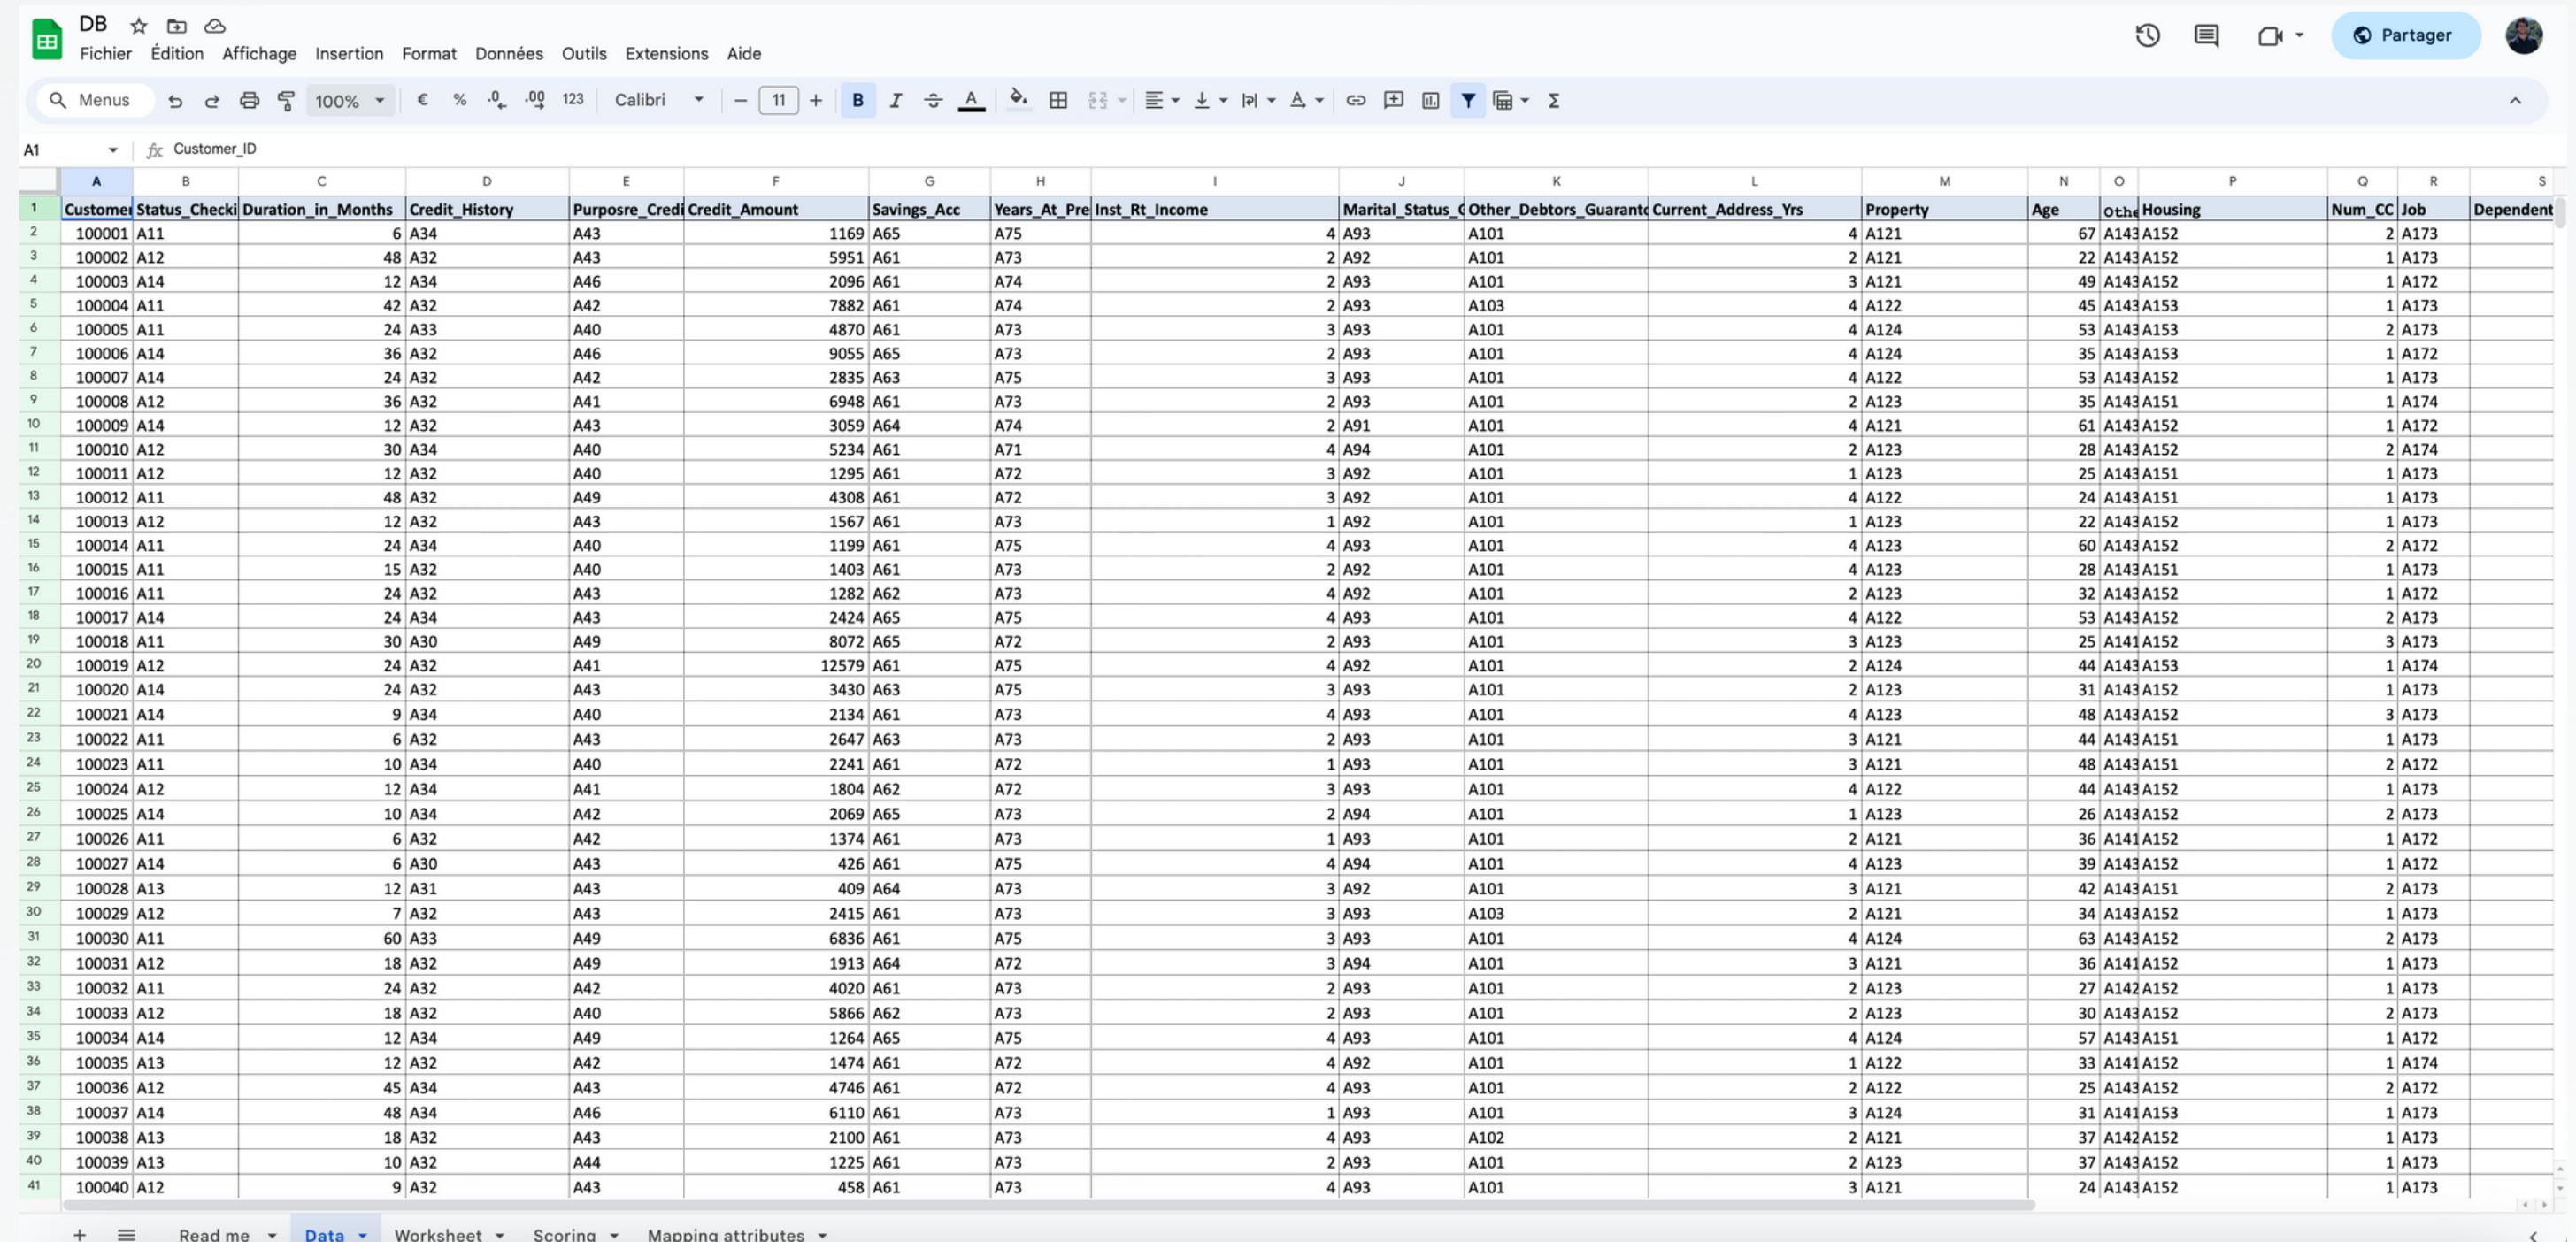
- Duration_in_Months : Durée du prêt en mois.
- Purposre_Credit_Taken: Motif de la demande de crédit.
- Housing : Situation de logement du client.
- Num_CC : Nombre de cartes de crédit du client.
- Job : Information sur l'emploi du client.
- Dependents : Nombre de personnes à charge du client.
- Telephone: Disponibilité d'une connexion téléphonique.
- Foreign_Worker: Statut de travailleur étranger.

Historique de Crédit :

- Credit_History : Informations sur le crédit antérieur du client.

COLLECTE ET PRÉTRAITEMENT DES DONNÉES

TYPES DE DONNÉES PERTINENTES ET LEUR IMPORTANCE



The screenshot shows a data analysis software interface with a spreadsheet containing customer data. The spreadsheet has 41 rows and 25 columns. The columns are labeled A through S and include fields such as Customer_ID, Customer_Status, Duration_in_Months, Credit_History, Purpose_Credit, Credit_Amount, Savings_Acc, Years_At_Pre, Inst_Rt_Income, Marital_Status, Other_Debtors_Guarantees, Current_Address_Yrs, Property, Age, Other_Housing, Num_CC, Job, and Dependent.

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
Customer_ID	Customer_Status	Duration_in_Months	Credit_History	Purpose_Credit	Credit_Amount	Savings_Acc	Years_At_Pre	Inst_Rt_Income	Marital_Status	Other_Debtors_Guarantees	Current_Address_Yrs	Property	Age	Other_Housing	Num_CC	Job	Dependent	
100001	A11	6	A34	A43	1169	A65	A75		4 A93	A101		4 A121	67	A143 A152	2	A173		
100002	A12	48	A32	A43	5951	A61	A73		2 A92	A101		2 A121	22	A143 A152	1	A173		
100003	A14	12	A34	A46	2096	A61	A74		2 A93	A101		3 A121	49	A143 A152	1	A172		
100004	A11	42	A32	A42	7882	A61	A74		2 A93	A103		4 A122	45	A143 A153	1	A173		
100005	A11	24	A33	A40	4870	A61	A73		3 A93	A101		4 A124	53	A143 A153	2	A173		
100006	A14	36	A32	A46	9055	A65	A73		2 A93	A101		4 A124	35	A143 A153	1	A172		
100007	A14	24	A32	A42	2835	A63	A75		3 A93	A101		4 A122	53	A143 A152	1	A173		
100008	A12	36	A32	A41	6948	A61	A73		2 A93	A101		2 A123	35	A143 A151	1	A174		
100009	A14	12	A32	A43	3059	A64	A74		2 A91	A101		4 A121	61	A143 A152	1	A172		
100010	A12	30	A34	A40	5234	A61	A71		4 A94	A101		2 A123	28	A143 A152	2	A174		
100011	A12	12	A32	A40	1295	A61	A72		3 A92	A101		1 A123	25	A143 A151	1	A173		
100012	A11	48	A32	A49	4308	A61	A72		3 A92	A101		4 A122	24	A143 A151	1	A173		
100013	A12	12	A32	A43	1567	A61	A73		1 A92	A101		1 A123	22	A143 A152	1	A173		
100014	A11	24	A34	A40	1199	A61	A75		4 A93	A101		4 A123	60	A143 A152	2	A172		
100015	A11	15	A32	A40	1403	A61	A73		2 A92	A101		4 A123	28	A143 A151	1	A173		
100016	A11	24	A32	A43	1282	A62	A73		4 A92	A101		2 A123	32	A143 A152	1	A172		
100017	A14	24	A34	A43	2424	A65	A75		4 A93	A101		4 A122	53	A143 A152	2	A173		
100018	A11	30	A30	A49	8072	A65	A72		2 A93	A101		3 A123	25	A141 A152	3	A173		
100019	A12	24	A32	A41	12579	A61	A75		4 A92	A101		2 A124	44	A143 A153	1	A174		
100020	A14	24	A32	A43	3430	A63	A75		3 A93	A101		2 A123	31	A143 A152	1	A173		
100021	A14	9	A34	A40	2134	A61	A73		4 A93	A101		4 A123	48	A143 A152	3	A173		
100022	A11	6	A32	A43	2647	A63	A73		2 A93	A101		3 A121	44	A143 A151	1	A173		
100023	A11	10	A34	A40	2241	A61	A72		1 A93	A101		3 A121	48	A143 A151	2	A172		
100024	A12	12	A34	A41	1804	A62	A72		3 A93	A101		4 A122	44	A143 A152	1	A173		
100025	A14	10	A34	A42	2069	A65	A73		2 A94	A101		1 A123	26	A143 A152	2	A173		
100026	A11	6	A32	A42	1374	A61	A73		1 A93	A101		2 A121	36	A141 A152	1	A172		
100027	A14	6	A30	A43	426	A61	A75		4 A94	A101		4 A123	39	A143 A152	1	A172		
100028	A13	12	A31	A43	409	A64	A73		3 A92	A101		3 A121	42	A143 A151	2	A173		
100029	A12	7	A32	A43	2415	A61	A73		3 A93	A103		2 A121	34	A143 A152	1	A173		
100030	A11	60	A33	A49	6836	A61	A75		3 A93	A101		4 A124	63	A143 A152	2	A173		
100031	A12	18	A32	A49	1913	A64	A72		3 A94	A101		3 A121	36	A141 A152	1	A173		
100032	A11	24	A32	A42	4020	A61	A73		2 A93	A101		2 A123	27	A142 A152	1	A173		
100033	A12	18	A32	A40	5866	A62	A73		2 A93	A101		2 A123	30	A143 A152	2	A173		
100034	A14	12	A34	A49	1264	A65	A75		4 A93	A101		4 A124	57	A143 A151	1	A172		
100035	A13	12	A32	A42	1474	A61	A72		4 A92	A101		1 A122	33	A141 A152	1	A174		
100036	A12	45	A34	A43	4746	A61	A72		4 A93	A101		2 A122	25	A143 A152	2	A172		
100037	A14	48	A34	A46	6110	A61	A73		1 A93	A101		3 A124	31	A141 A153	1	A173		
100038	A13	18	A32	A43	2100	A61	A73		4 A93	A102		2 A121	37	A142 A152	1	A173		
100039	A13	10	A32	A44	1225	A61	A73		2 A93	A101		2 A123	37	A143 A152	1	A173		
100040	A12	9	A32	A43	458	A61	A73		4 A93	A101		3 A121	24	A143 A152	1	A173		

COLLECTE ET PRÉTRAITEMENT DES DONNÉES

DÉFIS LIÉS À LA COLLECTE ET À LA QUALITÉ DES DONNÉES

- Collecte de Données Cruciale : La collecte de données pour l'étude sur l'évaluation des risques de crédit était une étape essentielle.
- Jeu de Données : Nous avons utilisé un jeu de données de Credit One Bank comprenant 5000 instances et 20 attributs, dont 7 étaient numériques et 13 catégoriques.
- Défi des Données Catégoriques : Les données catégoriques étaient essentielles mais présentaient des défis en raison de libellés au lieu de valeurs numériques directes.
- Solution de Mapping : Nous avons opté pour une approche de mapping utilisant des outils comme Excel, avec des formules telles que "arrayformula" et "vlookup" pour convertir les catégories en valeurs numériques.
- Qualité des Données : Une attention particulière a été accordée à la qualité des données, y compris la gestion des valeurs manquantes, des valeurs aberrantes et la validation de la cohérence des données.



MODÈLE SYNTHOSCORE

- Introduction au modèle SynthoScore
- Techniques de prétraitement des données pour les scores pondérés
- Techniques de prétraitement des données pour l'entraînement des modèles
- Explication des trois éléments : données actualisées, scores pondérés, régression logistique
- Résultats attendus grâce au modèle

INTRODUCTION AU MODÈLE SYNTHOSCORE

Le Modèle SynthoScore est conçu pour relever le défi de risque des crédits en tirant parti de trois éléments clés :

- Des données actualisées en temps réel
- Des scores pondérés méticuleusement calculés,
- Une puissante régression logistique.

Chacun de ces éléments contribue de manière significative à la précision et à la fiabilité de l'évaluation des risques de crédit.

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR LES SCORES PONDÉRÉS

- Scores individuels pour les caractéristiques clés : Des scores spécifiques ont été développés pour des caractéristiques essentielles telles que l'historique de crédit, le montant du crédit, la stabilité de l'emploi,
- Pondération des scores individuels : Les scores ont été pondérés en fonction de leur importance relative, déterminant ainsi leur contribution à l'évaluation globale du risque de crédit.
- Calcul du score pondéré global : Le score global pour chaque client est obtenu en combinant les scores pondérés individuels, ce qui permet de déterminer leur niveau de risque de crédit.
- Interprétation des scores pondérés : Les scores pondérés indiquent la probabilité de défaut de crédit, avec des scores plus élevés signifiant un risque moindre. Ils sont utilisés pour prendre des décisions sur les prêts et les termes associés.
- Mise à jour et réajustement : Les scores ne sont pas fixes et peuvent être actualisés pour tenir compte des changements dans la situation des clients ou de l'économie, garantissant ainsi une évaluation continue des risques de crédit.

MODÈLE SYNTHOSCORE

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR LES SCORES PONDÉRÉS

K3 **fx** =ArrayFormula(SI(A3:A<>"";(B3:B*\$B\$1)+(C3:C*\$C\$1)+(D3:D*\$D\$1)+(E3:E*E1)+(F3:F*F1)+(G3:G*G1)+(H3:H*H1)+(I3:I*I1)+(J3:J*J1);""))

	A	B	C	D	E	F	G	H	I	J	K
1		20%	20%	13%	10%	10%	7%	10%	5%	5%	=
2	Customer_ID	Status score	credit history sc	Credit_Amount	savings score	Years_At_Preser	Other_Debtors	Current_Addres	Job score	Property score	Score pondéré
3	100001	1	0	2	0	3	0	1	1	3	1,06
4	100002	2	1	1	0	1	0	0	1	3	1,03
5	100003	0	0	2	0	2	0	1	0	3	0,71
6	100004	1	1	1	0	2	2	1	1	2	1,12
7	100005	1	0	1	0	1	0	1	1	0	0,58
8	100006	0	1	1	0	1	0	1	0	0	0,53
9	100007	0	1	2	2	3	0	1	1	2	1,21
10	100008	2	1	1	0	1	0	0	2	1	0,98
11	100009	0	1	1	3	2	0	1	0	3	1,08
12	100010	2	0	1	0	0	0	0	2	1	0,68
13	100011	2	1	2	0	0	0	0	1	1	0,96
14	100012	1	1	1	0	0	0	1	1	2	0,78
15	100013	2	1	2	0	1	0	0	1	1	1,06
16	100014	1	0	2	0	3	0	1	0	1	0,91
17	100015	1	1	2	0	1	0	1	1	1	0,96
18	100016	1	1	2	1	1	0	0	0	1	0,91
19	100017	0	0	2	0	3	0	1	1	2	0,81
20	100018	1	2	1	0	0	0	1	1	1	0,93
21	100019	2	1	0	0	3	0	0	2	0	1
22	100020	0	1	1	2	3	0	0	1	1	0,93
23	100021	0	0	2	0	1	0	1	1	1	0,56
24	100022	1	1	2	2	1	0	1	1	3	1,26
25	100023	1	0	2	0	0	0	1	0	2	0,71

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Les bibliothèques Python Essentielles
Nous avons utilisé plusieurs bibliothèques
Python essentielles pour notre analyse et
la création de notre modèle.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import r2_score
import seaborn as sns
import plotly.express as px
import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec
```

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Étape de Division de la Base de Données :
Nous avons commencé par diviser notre ensemble de données en deux parties : datascore et data. Datascore a été utilisé pour entraîner notre modèle, tandis que data a servi à créer des visualisations. Nous avons retiré les colonnes non nécessaires de chaque ensemble.

```
##Diviser notre data
##db = datascore + data
##datascore pour entrainer notre model et data pour creer des visualisations

datascore = db.drop(['Customer_ID', 'Status_Checking_Acc',
'Duration_in_Months',
'Credit_History', 'Purposre_Credit_Taken', 'Credit_Amount',
'Savings_Acc', 'Years_At_Present_Employment', 'Inst_Rt_Income',
'Marital_Status_Gender', 'Other_Debtors_Guarantors',
'Current_Address_Yrs', 'Property', 'Age', 'Other_Inst_Plans',
'Housing',
'Num_CC', 'Job', 'Dependents', 'Telephone', 'Foreign_Worker',
'Default_On_Payment', 'Customer_ID.1'],axis=1)
data = db.drop(['Customer_ID','Customer_ID.1', 'Status score',
'credit history score', 'Credit_Amount score', 'savings score',
'Years_At_Present_Employment score', 'Other_Debtors_Guarantors
score',
```

MODÈLE SYNTHOSCORE

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Conversion en Valeurs Binaires : Pour appliquer notre modèle de régression logistique, nous avons converti les scores pondérés calculés précédemment en valeurs binaires. Ceci était essentiel pour la classification binaire du risque de crédit. Un score de 0 signifie qu'il y a un risque de crédit, tandis qu'un score de 1 signifie qu'il n'y a pas de risque de crédit.

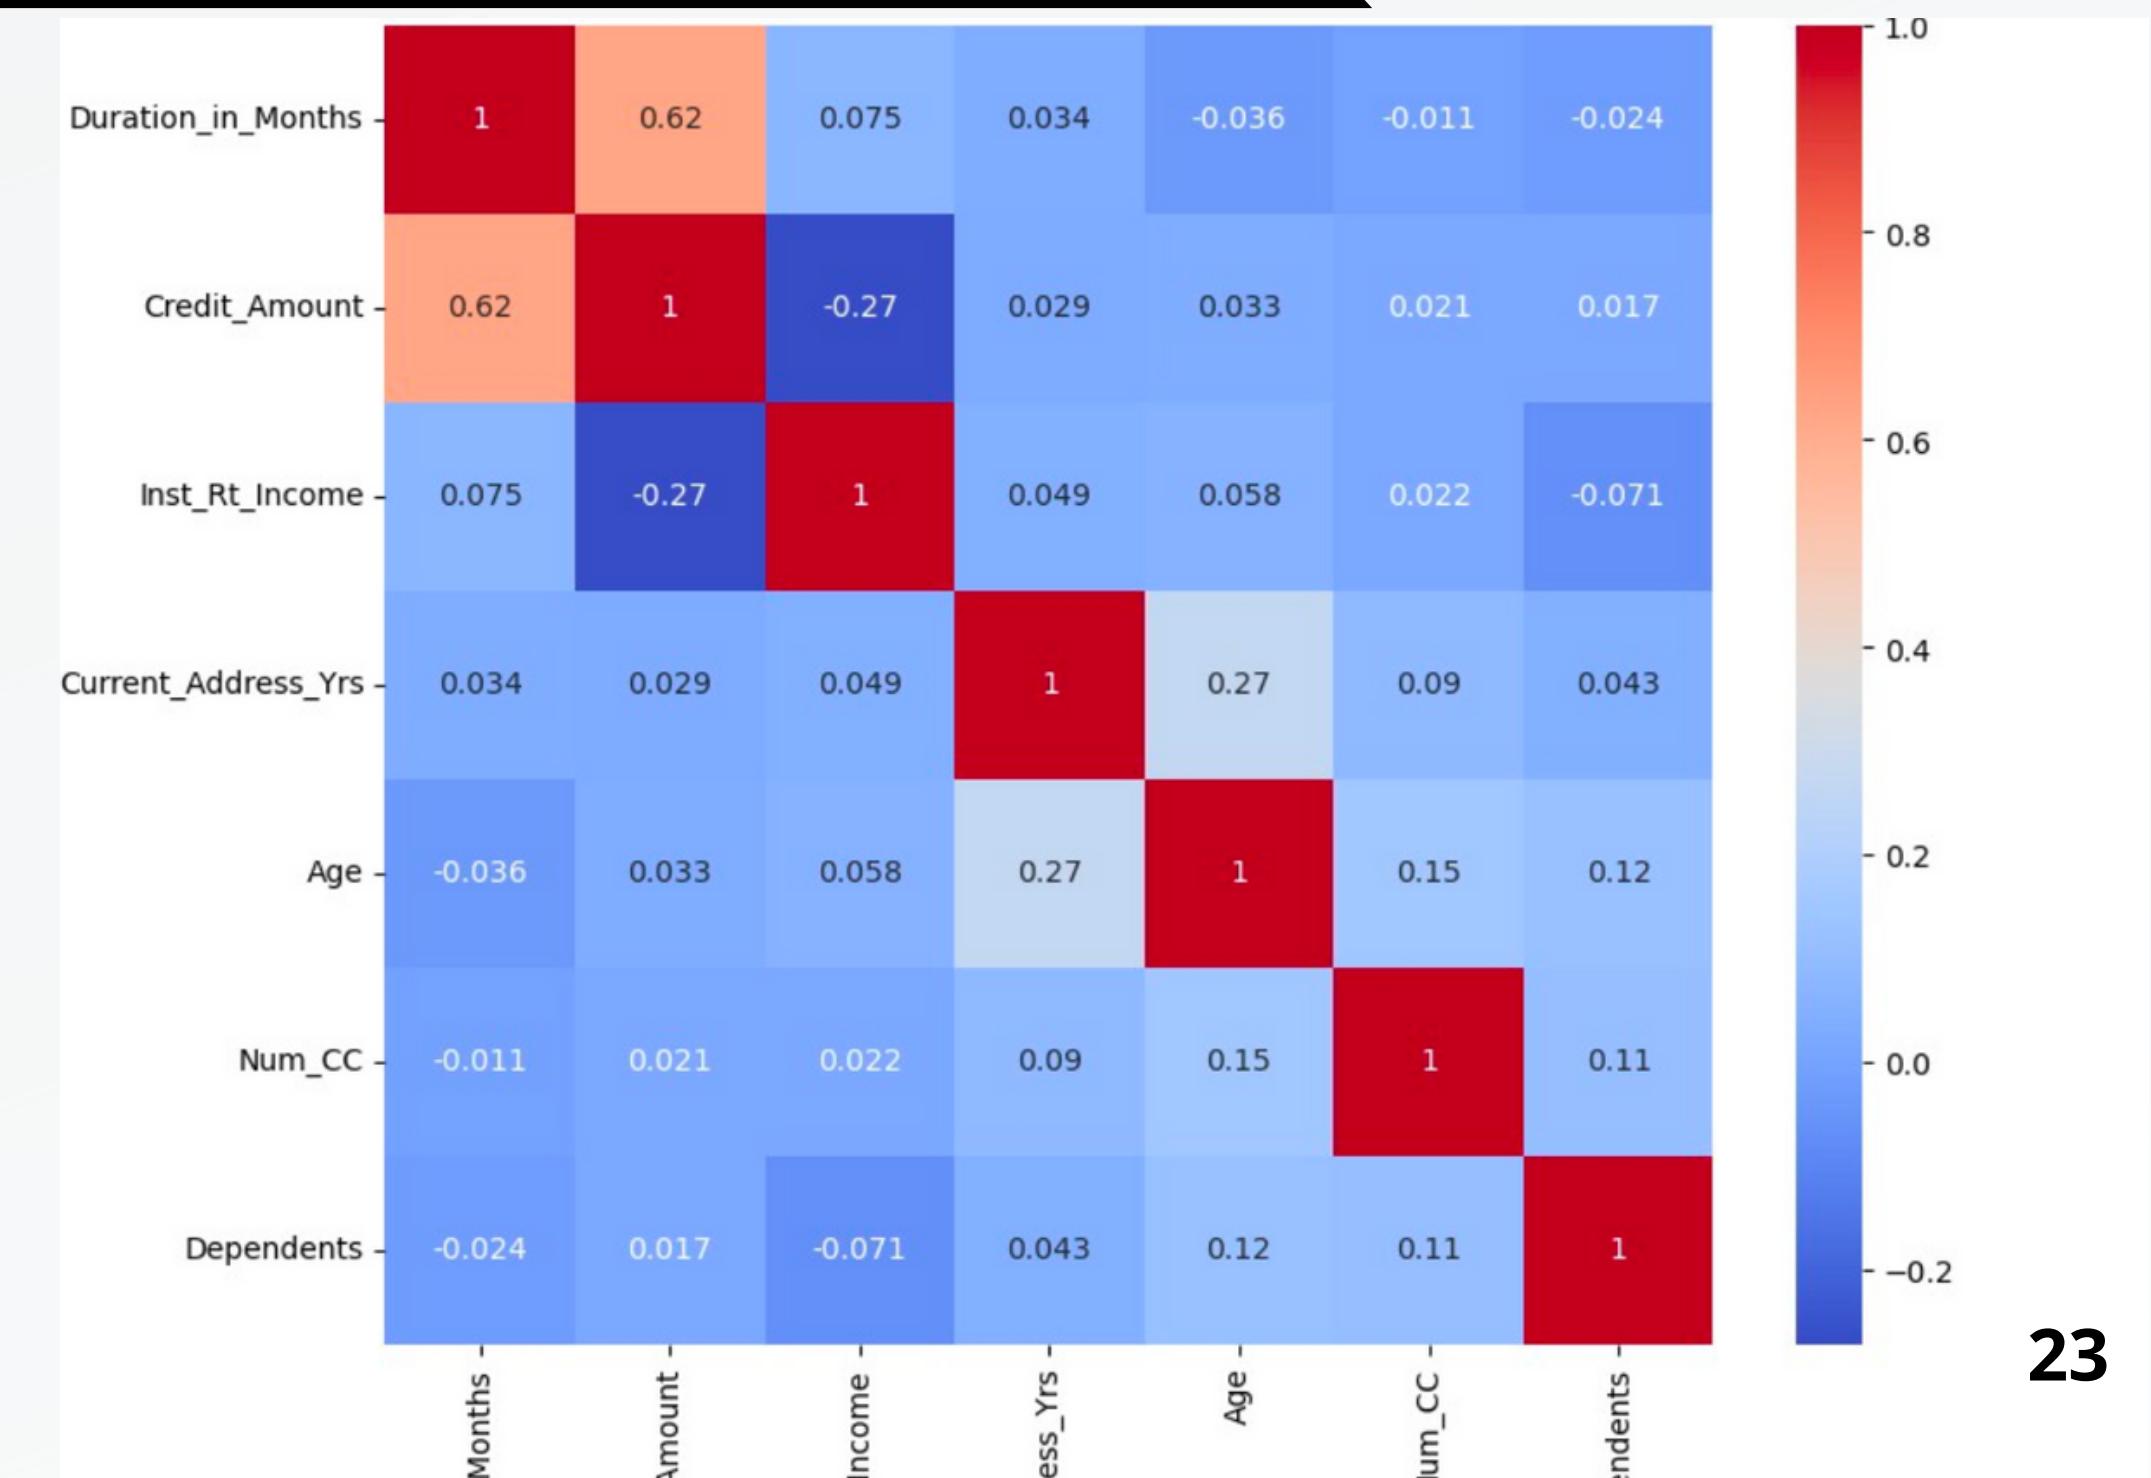
L3	J	K	L	M	N
1	5%				
2	Property score	Score pondéré	Score pondéré binaire		
3	3	1,06	1		
4	3	1,03	1		
5	3	0,71	0		
6	2	1,12	1		
7	0	0,58	0		
8	0	0,53	0		
9	2	1,21	1		
10	1	0,98	1		

MODÈLE SYNTHOSCORE

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Analyse de Corrélation :

Nous avons réalisé une analyse de corrélation pour explorer les relations entre les variables de notre jeu de données. Les résultats de cette analyse ont mis en évidence des tendances intéressantes. En particulier, nous avons observé une corrélation significative entre deux variables spécifiques : le montant du crédit et la durée en mois.



TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Cependant, il est important de noter que pour la plupart des autres variables de notre ensemble de données, nous n'avons pas observé de corrélations significatives, ou même des corrélations négatives. Cela indique que ces variables peuvent être relativement indépendantes les unes des autres et du résultat que nous cherchons à prédire, à savoir le risque de crédit. Cette diversité de corrélations souligne l'importance d'examiner chaque variable individuellement pour comprendre sa contribution à notre modèle de prédiction.

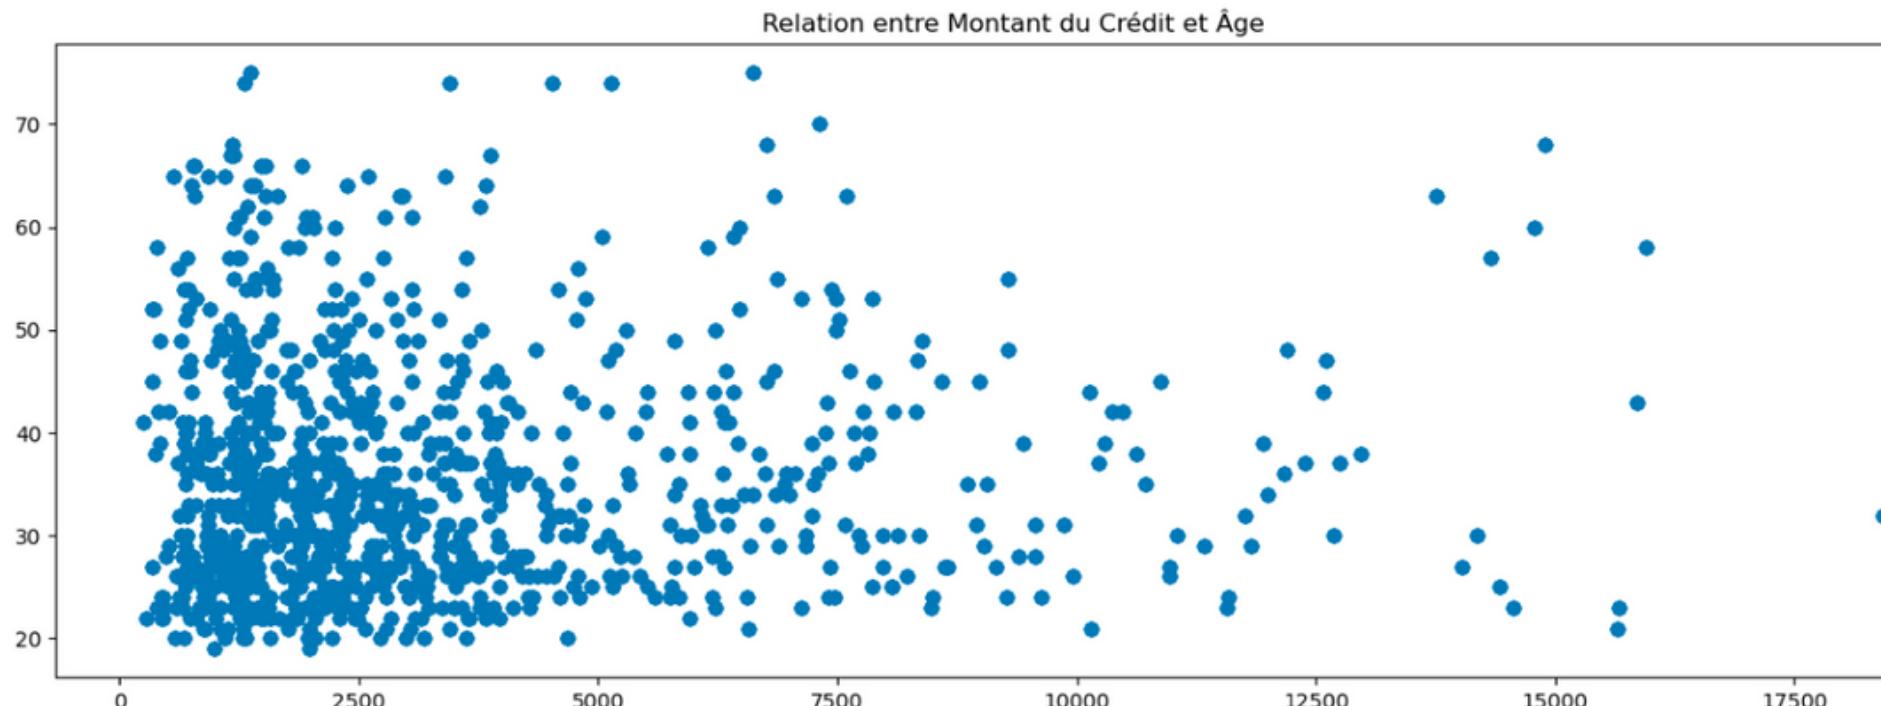
Par exemple, nous avons examiné la relation entre le montant du crédit et l'âge des emprunteurs. Nos visualisations ont révélé que la tranche d'âge la plus propice à la souscription de crédits se situe généralement entre 20 et 42 ans, avec des montants de crédit allant de 1000 à 6000 dollars.

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

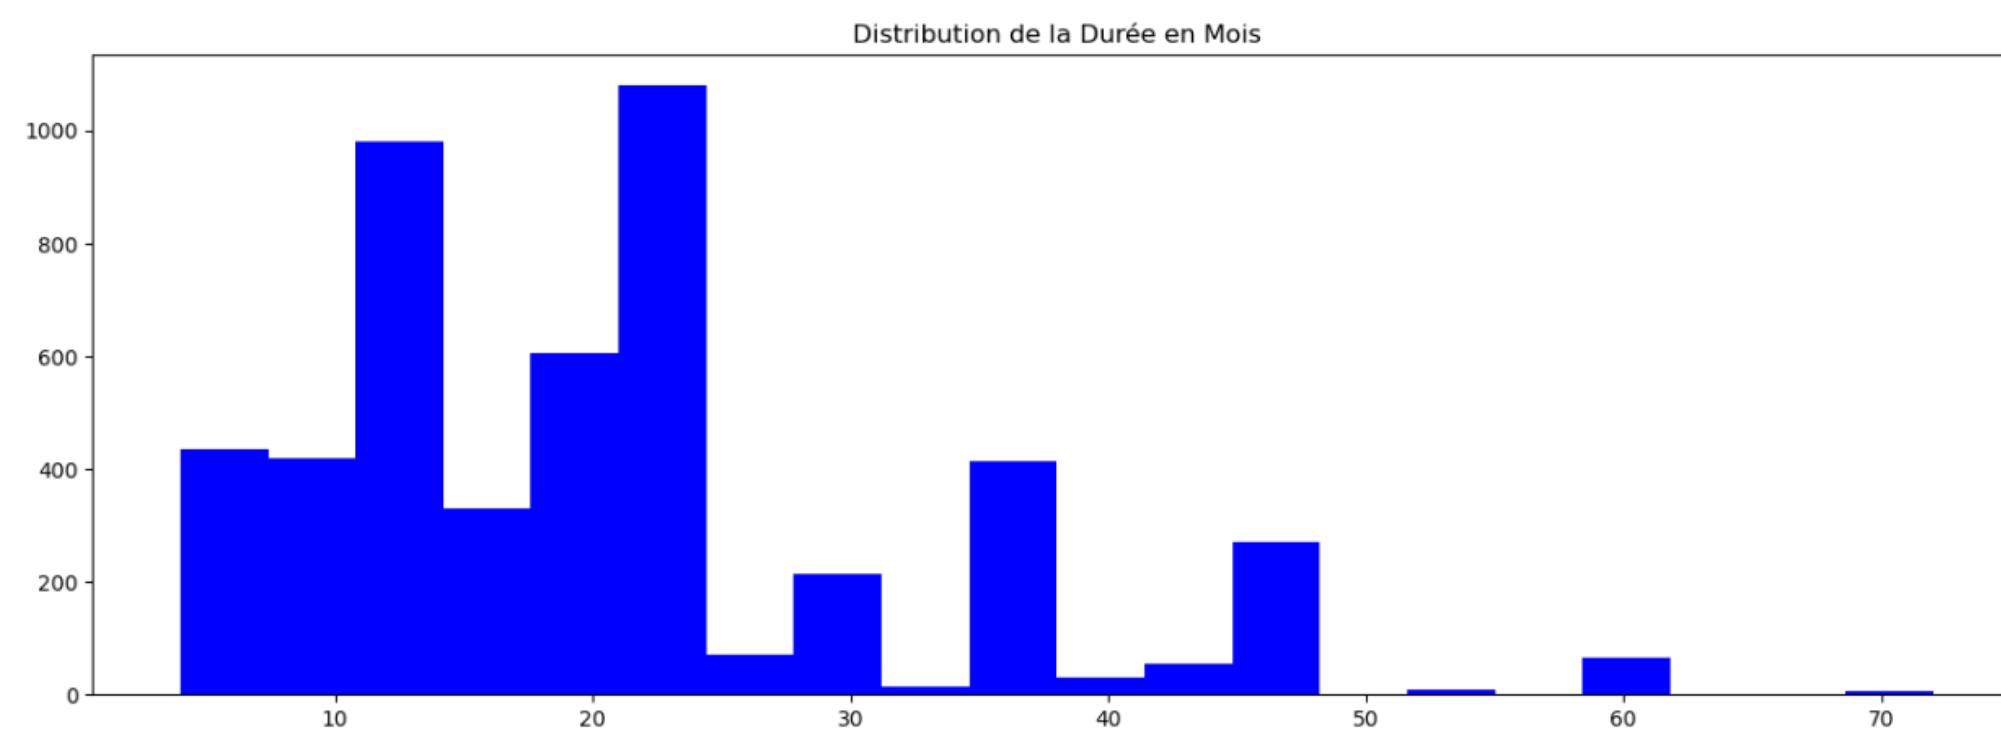
```
### Créer de visualisation pour voir la Relation entre Montant du Crédit et Âge
fig = plt.figure(figsize=(36, 12))
spec = gridspec.GridSpec(2, 2, figure=fig)

ax1 = fig.add_subplot(spec[0, 0])
ax1.scatter(db["Credit_Amount"],db["Age"])
ax1.set_title("Relation entre Montant du Crédit et Âge")

Text(0.5, 1.0, 'Relation entre Montant du Crédit et Âge')
```



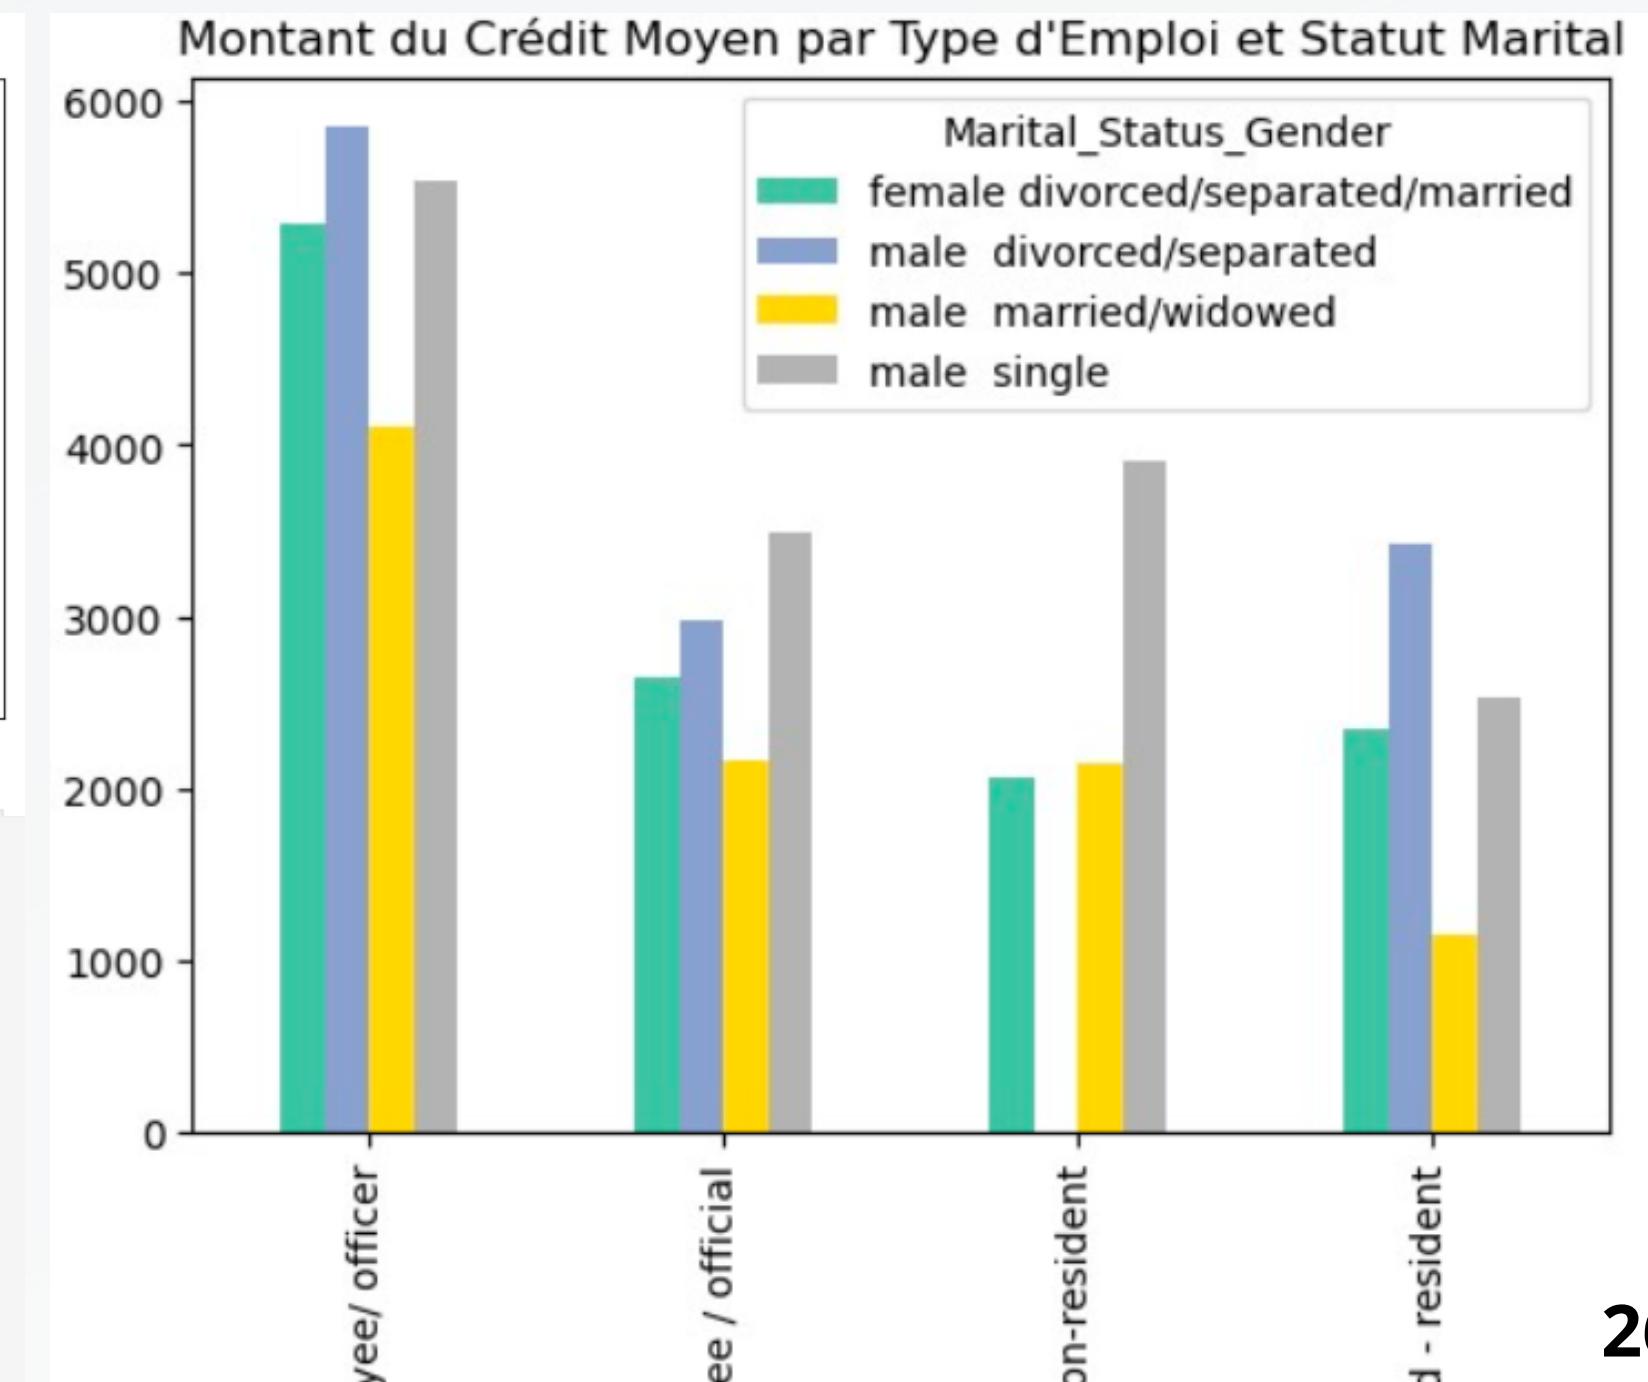
TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES



```
## Distribution de la Durée en Mois
fig = plt.figure(figsize=(36, 12))
spec = gridspec.GridSpec(2, 2, figure=fig)

ax2 = fig.add_subplot(spec[0, 1])
ax2.hist(db["Duration_in_Months"], bins=20, color="blue")
ax2.set_title("Distribution de la Durée en Mois")

Text(0.5, 1.0, 'Distribution de la Durée en Mois')
```



TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Application du Modèle :

Nous avons mis en application notre modèle d'apprentissage automatique, en particulier la régression logistique. Pour cela, nous avons préparé nos données pour l'entraînement du modèle. Notre ensemble de données se compose de deux parties principales : les caractéristiques (X) et la variable cible (Y).

```
X = datascore.drop(["Score pondéré binaire"], axis=1) # Supprimer
colonne Y
y = datascore["Score pondéré binaire"]
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Performance du Modèle :

En ce qui concerne les résultats de notre modèle, nous avons obtenu une précision de modèle exceptionnellement élevée de 0,995, ce qui signifie que notre modèle a correctement classé 99,5 % des échantillons de test. Cela suggère que notre modèle est très précis

```
accuracy = accuracy_score(y_test, y_pred)
print("Précision du modèle:", accuracy)

Précision du modèle: 0.995

r2 = r2_score(y_test, y_pred)
print("R-squared value:", r2)

R-squared value: 0.9799710782369742

cm = confusion_matrix(y_test, y_pred)
sns.heatmap(cm, annot=True, fmt="d")
plt.xlabel('Predicted')
plt.ylabel('True')
plt.show()
```

MODÈLE SYNTHOSCORE

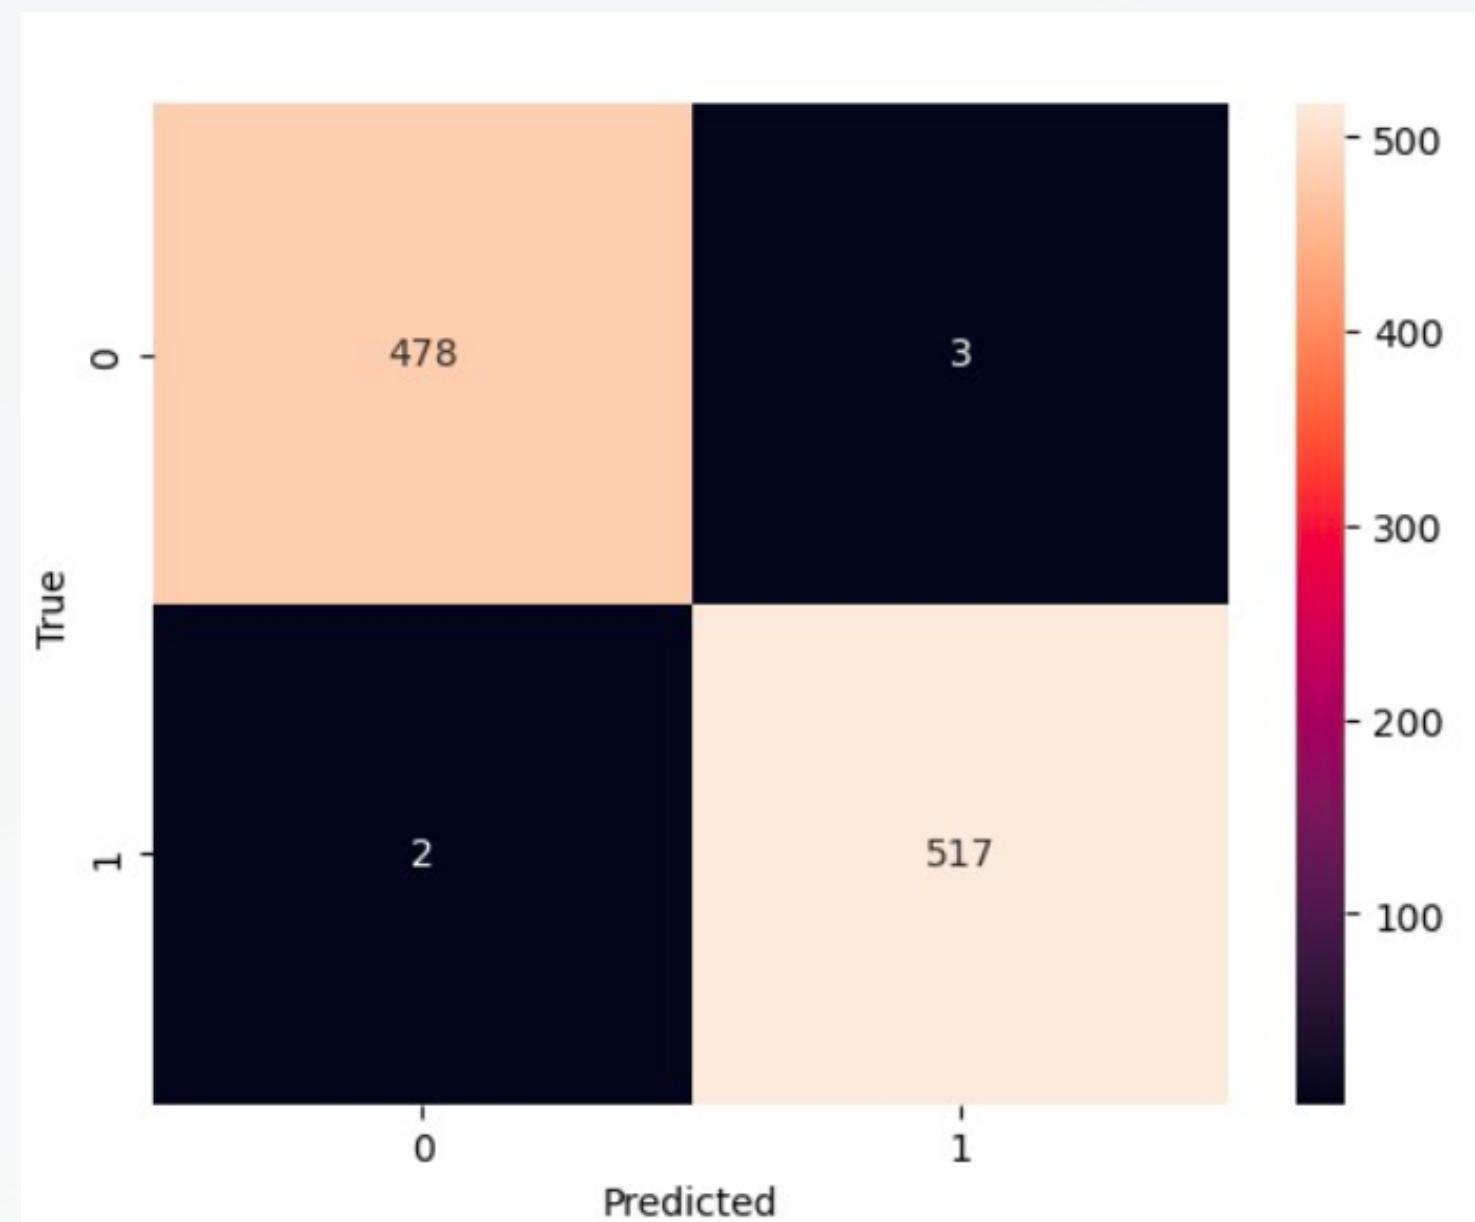
TECHNIQUES DE PRÉTRAITEMENT DES DONNÉES POUR L'ENTRAÎNEMENT DES MODÈLES

Vrais Positifs (VP) 478: Ce sont les cas où le modèle a correctement prédit la classe positive "risque de crédit" comme positifs. => il n'y a pas de risque de crédit

Vrais Négatifs (VN) 517: Ce sont les cas où le modèle a correctement prédit la classe négative "risque de crédit" comme négatifs. => il ya un risque de crédit

Faux Positifs (FP) 3: Ce sont les cas où le modèle a incorrectement prédit la classe négative comme positive

Faux Négatifs (FN) 2: Ce sont les cas où le modèle a incorrectement prédit la classe positive comme négative.





CONCLUSION

- Résumé des points clés
- Implications pour le secteur bancaire

CONCLUSION

- Réduction des prêts à risque
- Une meilleure gestion des portefeuilles de prêts
- Une réduction des pertes financières dues aux défauts de paiement



L'ÉCOLE DE L'INTELLIGENCE ARTIFICIELLE

SYNTHOSCORE

MERCI POUR VOTRE ATTENTION



JOUINI KHALIL